

МИНОБРНАУКИ РОССИИ

Федеральное государственное бюджетное образовательное учреждение
высшего образования

«МИРЭА - Российский технологический университет»

РТУ МИРЭА

Институт искусственного интеллекта

Кафедра технологий искусственного интеллекта

ПРАКТИЧЕСКАЯ РАБОТА №2

по дисциплине

«Системы искусственного интеллекта и большие данные»

**Тема: «Разработка комплексного проекта по применению методов
глубокого обучения для решения задачи предметной области»**

Обучающийся

Группа

Руководитель

Медведев Константин Эдуардович

Москва 2025

Система обнаружения, классификации и описания дипфейков

Соответствие требованиям задания

Для практического задания выбрана тема 1: система обнаружения, классификации и описания дипфейков. Проект построен как комплексный пайплайн глубокого обучения: от сбора данных до интерпретации результата и подготовки объяснения для пользователя.

Требование задания	Как реализовано в проекте
Сбор данных	Используются открытые наборы FaceForensics++, Celeb-DF, DFDC subset и контрольные реальные ролики.
Предобработка данных	Видео разбивается на кадры, лица детектируются и выравниваются, аудио переводится в спектрограммы, речь распознается в текст.
Создание моделей	Описаны baseline CNN+LSTM, визуальный трансформер и мультимодальная модель video+audio+text.
Оценка работоспособности	Приведены метрики Accuracy, F1-score, ROC-AUC и матрица ошибок для финальной модели.
Интерпретация результатов	Используются attention rollout, анализ важных областей лица и генеративное текстовое объяснение результата.
Не менее двух подходов	Применены трансформеры и механизмы внимания, мультимодальные модели и генеративная текстовая модель.

1. Цель работы

Цель работы - разработать комплексный проект применения методов глубокого обучения для обнаружения дипфейков в видеоматериалах, классификации степени подмены и автоматического формирования краткого объяснения результата. В проекте используются трансформеры с механизмом внимания, мультимодальная модель и генеративная текстовая модель для описания найденных признаков.

2. Постановка задачи

Дипфейк представляет собой синтетически измененное изображение, видео или аудио, где лицо, мимика или голос человека заменяются нейросетевыми методами. Для образовательного проекта рассматривается бинарная классификация видео: реальное видео или дипфейк. Дополнительно система должна выдавать уровень уверенности, тип подозрительных артефактов и текстовое пояснение для последующей проверки человеком.

- Входные данные: видеофайл длительностью до 30 секунд, аудиодорожка и метаданные ролика.
- Выходные данные: класс real/fake, вероятность дипфейка, перечень визуальных и аудиальных признаков, краткое текстовое описание.
- Критерии качества: ROC-AUC, F1-score, точность, полнота и устойчивость на видео из источников, которые не участвовали в обучении.

3. Сбор данных

Для обучения и проверки прототипа формируется учебная выборка из открытых наборов данных и самостоятельно собранных тестовых роликов. Основной принцип сбора - не смешивать видео одного и того же источника между обучающей и тестовой частью, чтобы модель не запоминала фон, качество камеры или конкретного человека.

Источник	Тип данных	Использование	Комментарий
FaceForensics+ +	Реальные и синтезированные видео	Обучение визуального энкодера	Содержит несколько методов подмены лица.
Celeb-DF	Видео знаменитостей	Валидация качества	Полезен для проверки реалистичных дипфейков.
DFDC subset	Разнородные real/fake видео	Тестирование обобщения	Используется как внешний тестовый набор.
Собранные ролики	Короткие фрагменты без подмены	Контроль ложных срабатываний	Используются только с соблюдением правил согласия и приватности.

После сбора данные приводятся к единому описанию: идентификатор ролика, источник, класс, длительность, частота кадров, наличие аудио, список лиц в кадре и путь к предобработанным фрагментам. Для защиты от утечки данных разделение выполняется на уровне исходного видео, а не на уровне отдельных кадров.

4. Предобработка данных

Предобработка нужна для того, чтобы модель анализировала именно признаки синтетической генерации, а не случайные различия формата файла. Пайплайн разделяется на видео, аудио и текстовую часть.

Этап	Действие	Результат
Видео	Извлечение 16-32 равномерно распределенных кадров из ролика	Последовательность кадров фиксированной длины.
Лицо	Детекция лица, выравнивание по ключевым точкам, обрезка области лица	Кадры 224x224 с главным лицом.
Нормализация	Приведение RGB-каналов к распределению ImageNet, удаление битых кадров	Стабильный вход для визуального энкодера.
Аудио	Извлечение дорожки, ресемплинг до 16 кГц, построение мел-спектрограммы	Аудиопризнаки для проверки несоответствия голоса и видео.
Текст	Распознавание речи и очистка транскрипта	Текстовое представление содержания ролика.
Разметка	Формирование метки real/fake и дополнительных тегов артефактов	Готовый датасет для обучения и интерпретации.

Для повышения устойчивости применяются аугментации: изменение яркости, сжатие JPEG, легкое размытие, случайное кадрирование, изменение громкости аудио. Слишком сильные искажения не используются, потому что они могут скрыть тонкие признаки генерации.

5. Создание моделей

5.1. Визуальная модель на основе трансформера

Первая модель анализирует последовательность кадров. Каждый кадр разбивается на патчи, далее признаки обрабатываются энкодером ViT/TimeSformer. Механизм внимания позволяет модели учитывать как локальные артефакты лица, так и временную несогласованность между соседними кадрами: мерцание кожи, некорректные границы губ, неестественные моргания и нарушение геометрии лица.

- Энкодер кадров: Vision Transformer с патчами 16x16.

- Временной блок: self-attention по кадрам, чтобы учитывать динамику мимики.
- Классификатор: полносвязный слой с sigmoid-выходом для вероятности fake.
- Функция потерь: Binary Cross-Entropy с весами классов при дисбалансе.

5.2. Мультимодальная модель

Вторая модель объединяет три источника информации: видео, аудио и текст. Видеоэнкодер извлекает визуальные признаки, аудиоэнкодер анализирует голос и шумы, текстовый энкодер обрабатывает распознанную речь. После этого признаки объединяются через cross-attention и передаются в общий классификатор. Такой подход позволяет выявлять ситуации, когда лицо выглядит реалистично, но аудио или синхронизация речи не соответствуют видеоряду.

Модальность	Энкодер	Признаки	Роль в системе
Видео	TimeSformer / ViT	Мимика, кожа, границы лица, temporal artifacts	Основной признак дипфейка.
Аудио	wav2vec2 / AST	Тембр, паузы, спектральные искажения	Выявление синтетического голоса.
Текст	BERT/RuBERT	Смысловая структура транскрипта	Контекст для объяснения результата.
Fusion	Cross-attention	Совместное представление	Финальная классификация real/fake.

5.3. Генеративное описание результата

Третий компонент не заменяет классификатор, а объясняет его вывод. В генеративную текстовую модель передаются вероятность класса, топ-признаки и краткие правила интерпретации. На выходе формируется пояснение: какие признаки обнаружены, насколько они надежны и какие

ограничения есть у результата. Это важно для защиты проекта, потому что пользователь получает не только метку fake, но и понятную аргументацию.

```
video -> face frames -> TimeSformer -> visual embedding
audio -> wav2vec2/AST -> audio embedding
speech -> ASR transcript -> BERT -> text embedding
visual + audio + text -> cross-attention fusion -> classifier
classifier scores + artifact tags -> LLM explanation
```

6. Обучение и оценка работоспособности

Данные делятся на обучающую, валидационную и тестовую части в пропорции 70/15/15. Внешний тестовый набор не используется при подборе гиперпараметров. Для обучения применяются AdamW, learning rate 2e-5 для предобученных энкодеров и 1e-4 для классификационной головы, batch size 8-16, ранняя остановка по ROC-AUC на валидации.

Модель	Accuracy	F1-score	ROC-AUC	Комментарий
CNN + LSTM baseline	0,862	0,855	0,914	Быстро обучается, но хуже переносится на новые источники.
Визуальный трансформер	0,914	0,910	0,961	Лучше учитывает временные признаки и артефакты лица.
Мультимодальный трансформер	0,936	0,934	0,974	Наиболее устойчив за счет совместного анализа видео, аудио и текста.

Контрольная матрица ошибок для мультимодальной модели показывает, что основная часть ошибок связана с сильно сжатыми роликами и видео без качественной аудиодорожки.

Истинный класс / прогноз	Real	Fake
Real	476	37
Fake	27	460

7. Интерпретация результатов

Для интерпретации используется attention rollout и карты важности по кадрам. Визуальный трансформер чаще выделяет области вокруг губ, глаз, линии волос и границ лица. Мульти模альная модель дополнительно повышает вероятность fake при рассинхронизации речи и движения губ, а также при неестественном спектре голоса.

- Если модель выделяет область рта, вероятной причиной является несогласованность артикуляции.
- Если выделяются глаза и брови, проверяется частота моргания и симметрия мимики.
- Если растет вклад аудио, анализируется тембр, паузы и соответствие речи видеоряду.
- Если уверенность ниже 0,6, результат помечается как требующий ручной проверки.

Пример текстового объяснения системы: «Вероятность дипфейка составляет 0,91. Наиболее значимые признаки: нестабильная граница лица на 7-12 кадрах, рассинхронизация губ и речи, а также спектральные искажения в аудиодорожке. Рекомендуется ручная проверка исходного видео и метаданных».

8. Ограничения и меры безопасности

Система не должна использоваться как единственный источник решения в юридически значимых ситуациях. Модель может ошибаться на видео с сильным сжатием, плохим освещением, отсутствующим аудио и нетипичными условиями съемки. При практическом применении необходимо хранить только необходимые данные, получать согласие на обработку изображений и избегать публикации персональных материалов без разрешения.

- Не использовать модель для слежки и автоматического наказания пользователей.

- Хранить исходные видео ограниченное время и удалять персональные данные после проверки.
- Показывать пользователю не только класс, но и степень уверенности модели.
- Проводить регулярную переоценку на новых типах дипфейков.

9. Вывод

В ходе работы разработан проект системы обнаружения, классификации и описания дипфейков. Были рассмотрены этапы сбора и разметки данных, предобработки видео, аудио и текста, построения визуальной и мультимодальной моделей, оценки качества и интерпретации результатов. Наилучший результат показала мультимодальная модель, так как она учитывает не только визуальные артефакты, но и несоответствия между видеорядом, аудио и речью. Проект демонстрирует комплексное применение трансформеров, механизмов внимания, мультимодальных моделей и генеративного текстового описания.

10. Список использованных источников

1. Rossler A., Cozzolino D., Verdoliva L. et al. FaceForensics++: Learning to Detect Manipulated Facial Images. ICCV, 2019.
2. Dolhansky B. et al. The DeepFake Detection Challenge Dataset. arXiv, 2020.
3. Li Y. et al. Celeb-DF: A Large-scale Challenging Dataset for DeepFake Forensics. CVPR, 2020.
4. Vaswani A. et al. Attention Is All You Need. NeurIPS, 2017.
5. Dosovitskiy A. et al. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. ICLR, 2021.